

# Лабораторная работа № 1 «Методы предварительной обработки данных для решения задач машинного обучения»

А.М. Смирнов, старший преподаватель кафедры ИУ-10 «Защита информации»

МГТУ им. Н.Э.Баумана

Москва, 2026

# Структура лабораторных работ (ЛР) по курсу

- 2 этапа — собственно выполнение и защита результатов.
- Доступ к заданиям лабораторных работ по ссылке:  
<https://cloud.mail.ru/public/X8xH/1e1gqzENs>.
- Отчет по ЛР формирует каждый студент отдельно, а руководитель бригады высылает все отчеты бригады на почту:  
[smirnovanton.m@mail.ru](mailto:smirnovanton.m@mail.ru).
- Отправка отчетов на вышеуказанную почту осуществляется после успешной защиты ЛР.

# Основные библиотеки и инструменты

- scikit-learn — содержит ряд современных алгоритмов машинного обучения и документацию по ним.
- NumPy — возможности для работы с многомерными массивами, операции линейной алгебры, ГПСЧ.
- SciPy — продвинутые процедуры линейной алгебры, обработка сигналов, специальные математические функции.
- matplotlib — построение графиков.
- pandas — библиотека для обработки и анализа данных, представляемых в DataFrame-таблице.

# Предварительная обработка данных и масштабирование

- StandardScaler — гарантирует, что для каждого признака значение выборочного среднего равно нулю, а дисперсия — 1.
- RobustScaler — аналогично переводит данные в один масштаб но вместо выборочного среднего и дисперсии, использует медиану и квартили.
- MinMaxScaler сдвигает данные таким образом, чтобы они находились в диапазоне строго от 0 до 1.
- Normalizer — каждая точка данных масштабируется таким образом, что его евклидова норма была равна 1.

# Масштабирование. Пример визуализации

```
In[2]:  
mglearn.plots.plot_scaling()
```




Рис.: Различные способы масштабирования и предварительной обработки данных

# Обработка категориальных признаков

- Категориальная переменная вместо диапазона имеет фиксированный список возможных значений и обозначает качественный признак.
- Для обработки таких признаков используют метод прямого кодирования.
- Основная идея метода — заменить категориальную переменную одной или несколькими новыми признаками, которые могут принимать значения 0 и 1.
- В библиотеке pandas — используется метод `get_dummies(data)`.

# Отбор признаков с помощью одномерной статистики

- Отбор признаков, сильнее всего связанных с зависимой переменной (имеющие уровень значимости, не превышающий заданного порогового значения).
- Используется библиотека `scikit-learn`.
- Для реализации одномерного отбора признаков, необходимо выбрать тест (обычно `f_classif`) и метод исключения признаков (самый простой `SelectKB`) с выбором фиксированного числа признаков.

# Работа с текстовыми данными. Модель «мешок слов»

- Токенизация. Каждый документ разбивается на слова.
- Все различные слова собираются в словарь.
- Построение разреженной матрицы. Подсчитывается частота каждого слова в документе.
- Модель мешка слов реализована в классе CountVectorizer.

# Работа с текстовыми данными. Масштабирования с помощью tf-idf

- Метод частота термина — обратная частота документа (tf-idf).
- Идея: присвоить большой вес термину, который часто встречается в конкретном документе, но редко в остальных документах корпуса.
- Признаки с низкими значениями tf-idf – это признаки, которые либо встречаются во многих документах, либо используются редко и только в очень длинных документах
- В библиотеке scikit-learn метод tf-idf реализован в классе TfidfTransformer.
- Значение tf-idf для слова  $w$  в документе  $d$  вычисляется по формуле:

$$tfidf(w, d) = tf \log \left( \frac{N + 1}{N_w + 1} \right) + 1,$$

где  $tf$  — частота термина в документе,  $N$  — количество документов в наборе,  $N_w$  — это количество документов набора, в котором встретилось слово  $w$ .

# Задание

- Найти и загрузить датасет, содержащий как категориальные, так и числовые признаки. Для каждого варианта — свой датасет.
- Реализовать масштабирование данных различными способами (StandardScaler, RobustScaler, MinMaxScaler, Normalizer).
- Кодирование категориальных признаков реализовать методом прямого кодирования. В качестве вывода представить преобразованную таблицу.
- С помощью одномерных статистик реализовать отбор признаков, имеющих уровень значимости, не превышающих заданного порогового значения.
- Для заданных текстов провести предварительную обработку данных с помощью модели «мешок слов», масштабирование с помощью модели tf-idf.

# Структура отчета по Лабораторной работе

- Постановка задачи. Содержит полное описание задания в соответствии с файлом задания.
- Ход работы. Содержит полное описание алгоритма работы в словесной форме, математическую модель используемых алгоритмов, листинг программы.
- Обработка результатов. Содержит как входные данные, приведенные в файле, так и полученные авторами решения результаты.
- Выводы.

Вопросы???